


ML Crypto Arbitrage

Высокочастотная система обработки и paper-тестирования арбитражных стратегий на криптовалютных рынках. Платформа получает L2-стаканы и OHLCV, формирует межрыночные пары, оценивает перспективность спреда и управляет входом и выходом с помощью ML-подходов.

Идея проекта: не предсказывать цену отдельного актива, а обрабатывать временные ценовые расхождения между связанными рынками и оценивать, можно ли их исполнить с учётом глубины стакана, задержки и комиссий.



Навигация

- [О проекте](#)
- [Основные результаты](#)
- [Обработка данных](#)
- [ML-модели](#)
- [Архитектура системы](#)
- [Запуск](#)
- [Исторический replay](#)
- [Структура проекта](#)

О проекте

Система работает с двумя типами арбитражных пар:

- **spot-perp** на одной бирже;
- **perp-perp** между разными биржами.

Каждые 100 мс сервис обновляет состояние рынка, строит признаки и получает предсказания моделей. После этого независимые стратегии могут открыть, удерживать или закрыть позицию. Исполнение моделируется по пяти уровням L2, а в итоговом PnL учитываются задержка, доступный объём и четыре taker-комиссии полного торгового круга.

В проекте реализованы:

- обработка L2 и закрытых свечей **1m/5m**;
- единая временная сетка 100 мс без использования будущих данных;
- квантильный регрессор, Transformer и RL-агент;
- реалистичный paper execution по глубине стакана;
- детерминированное воспроизведение исторического рынка;
- API и dashboard для наблюдения за моделями и стратегиями.

Основные результаты

Этап	Результат
Объём исходных данных	719,6 млн L2-снимков с 5 бирж
Естественные эпизоды спреда	41 240
Эпизоды со схождением не менее 40 bps	51,9%
Отбор спреда, q35	Average Precision 0,908; Spearman 0,799
Выбор входа и выхода, Transformer	85,4% прибыльных входов
Потеря относительно лучшего входа	31,0 bps
Потеря относительно лучшего выхода	7,7 bps

Все значения получены на зафиксированных validation/test-интервалах исторического рынка.

Обработка данных

Пайплайн обработки данных в ML Service




Данные проходят валидацию и дедупликацию, после чего последние доступные L2-снимки и только закрытые OHLCV-свечи объединяются в причинное состояние рынка. Для совместимых инструментов строятся оба направления сделки и признаки для моделей.

Распределение возможностей

На графике показано максимальное схождение, которое наблюдалось внутри каждого естественного эпизода спреда.

Распределение лучших возможностей внутри эпизодов



ML-модели

Q35 Regressor

Квантильный **HistGradientBoostingRegressor** оценивает величину будущего схождения. Регрессия с пороговым отбором сохранила информацию о размере возможности, а квантиль **q35** снизил риск опасных завышений прогноза.

Multiscale Transformer


Две attention-ветви анализируют плотную локальную и разреженную долгосрочную историю L2. Полученное представление объединяется с OHLCV и категориальными признаками пары. Отдельные головы оценивают перспективность спреда, качество входа и целесообразность выхода.

LSTM Double-DQN

MLP-кодировщик и LSTM сохраняют историю рынка, после чего Q-функция выбирает действие **WAIT**, **ENTER**, **HOLD** или **EXIT**. Агент активируется после предварительного q35-отбора, чтобы обучаться на более информативных рыночных последовательностях.


Отбор прибыльного спреда

Отбор прибыльного спреда: q35 и Transformer




Оптимальность входа

Оптимальность входа: Transformer + RL LSTM-DQN



Оптимальность выхода


Оптимальность выхода: Transformer + RL LSTM-DQN



Сравнение полных стратегий

Сравнение прибыльности ML-стратегий

Тестовая выборка · L2-исполнение · комиссии учтены · \$100 на каждую ногу



Сравнение выполнено в offline backtest на историческом test-потоке с одинаковым контрактом комиссий и исполнения.

Архитектура системы

flowchart LR

FEED["Live feed или replay"] --> API["ML Service"]

API --> STATE["Состояние рынка"]

STATE --> FEATURES["Признаки, 100 мс"]

```

FEATURES --> Q35["q35"]
FEATURES --> TF["Transformer"]
FEATURES --> RL["LSTM Double-DQN"]

Q35 --> STRATEGIES["Paper-стратегии"]
TF --> STRATEGIES
RL --> STRATEGIES

STRATEGIES --> EXECUTION["Исполнение по L2"]
EXECUTION --> METRICS["Метрики и события"]
METRICS --> DASHBOARD["Dashboard"]

```

Сервис	Порт	Назначение
ML_service	8080	Состояние рынка, признаки, модели и paper trading
market_simulator	8090	Подготовка и воспроизведение исторического потока
dashboard_service	3000	Интерфейс оператора

Запуск

Docker Compose

```

cd ML_service
cp .env.example .env
docker compose up -d --build ml-service dashboard-service

```

После запуска:

- Dashboard: <http://localhost:3000>
- ML API: <http://localhost:8080/docs>
- Проверка готовности: <http://localhost:8080/health/ready>

CUDA

Для запуска Transformer и RL на NVIDIA GPU:

```

cd ML_service
docker compose -f compose.yaml -f compose.cuda.yaml up -d --build

```

Конкретную видеокарту можно выбрать в `.env`:

```

ML_DEVICE=cuda
NVIDIA_VISIBLE_DEVICES=0

```

Q35-модель всегда выполняется на CPU.

Исторический replay

Большие рыночные данные намеренно не хранятся в репозитории. Для replay положите файлы:

```
ML_service/raw_last_3d/
├─ l2_raw.parquet
└─ ohlcv_raw.parquet
```

Подготовьте компактный участок рынка:

```
cd ML_service
docker compose --profile replay run --rm market-simulator \
  python -m market_simulator.prepare \
  --l2 /data/l2_raw.parquet \
  --ohlcv /data/ohlcv_raw.parquet \
  --output /prepared \
  --max-pairs 8 \
  --min-concurrent-seconds 900 \
  --overwrite
```

Запустите сервисы:

```
docker compose --profile replay up -d --build
```

Запустите 15 минут виртуального рынка:

```
curl -X POST http://localhost:8090/v1/replay/start \
  -H 'content-type: application/json' \
  -d '{"speed": 1, "duration_seconds": 900}'
```

Тесты

```
cd ML_service
python -m pytest -q

cd ../market_simulator
python -m pytest -q
```


Тесты проверяют причинную обработку признаков, контракты моделей, исполнение по стакану, работу paper-движка и корректность исторического replay.

Структура проекта

```
ML_crypto_arb/
├── assets/                # графики и изображения README
├── ML_service/           # ML-инференс и paper trading
│   ├── config/          # модели, стратегии и параметры сервиса
│   ├── models/          # готовые model bundles
│   ├── scripts/         # упаковка обученных моделей
│   ├── src/ml_service/  # API, признаки, модели и execution
│   └── tests/
├── market_simulator/    # исторический replay L2/OHLCV
│   ├── src/market_simulator/
│   └── tests/
├── dashboard_service/    # статический интерфейс оператора
│   └── web/
├── .gitignore
└── README.md
```

Технологии

- Python, FastAPI, Polars и NumPy;
- scikit-learn и PyTorch;
- L2 order book и OHLCV;
- Docker Compose и NVIDIA CUDA;
- HTML, CSS, JavaScript и Nginx;
- SQLite или in-memory paper state.